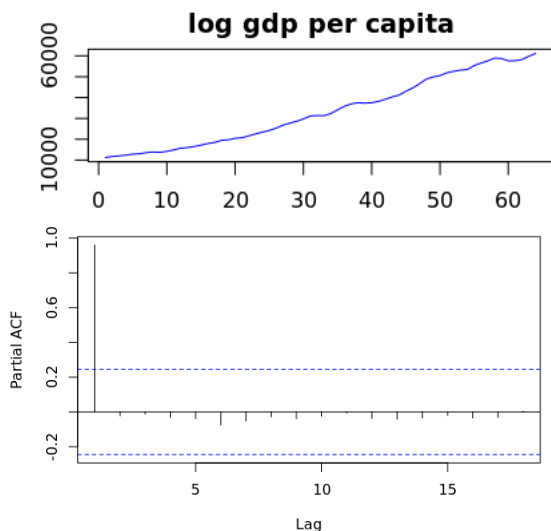


# Отчёт №1 студента БЭК195 Чесноковой Елены

## Построение прогноза для реального ВВП на душу населения в Норвегии

### 1. Анализ стационарности

ВВП на душу населения измеряется в годах, и в данной ситуации сезонность не влияет. Логарифмируем показатель, так как он не может быть отрицательным и может быть в виде функции экспоненты.



Проверяем показатель на стационарность.  
Проверим расф.

Из графика следует, что у нас один значимый лаг.  
Делаем тест Дики-Фуллера.

Мы получаем, что значение теста 0.806, что больше критического значения, поэтому мы не отвергаем гипотезу и нестационарности, соответственно ВВП на душу населения в Норвегии – нестационарный показатель.

Построим первую разность:

Value of test-statistic is: 0.806 6.3635

Critical values for test statistics:


	1pct	5pct	10pct
tau2	-3.51	-2.89	-2.58
phi1	6.70	4.71	3.86

Value of test-statistic is: -4.3529 9.4751

Critical values for test statistics:

	1pct	5pct	10pct
tau2	-3.51	-2.89	-2.58
phi1	6.70	4.71	3.86


Полученный показатель больше критического значение и поэтому мы отвергаем гипотезу о нестационарности метрики. Тогда отсюда возьмём значимые лаги для построения моделей. Для этого смотрим PACF (для модели AR) и можем выделить один значимый лаг – 1.



## 2. Анализ различий между спецификациями моделей AR, MA и ARMA

### Построение модели MA

Используем ACF для взятого показателя. На графике видим, что значим лаг 1. Таким образом строим модель для него и делаем это с помощью функции ARIMA.




```
ma_gdp_1lag= Arima(data$log_gdp, c(0,1,1), include.constant =TRUE,
method = c("CSS-ML"))
coefest(ma_gdp_1lag)
Acf(residuals(ma_gdp_1lag))
Box.test(residuals(ma_gdp_1lag), lag = 3, type = c("Ljung-Box"), fitdf
= 1)
```

z test of coefficients:

	Estimate	Std. Error	z value	Pr(> z )	
ma1	0.3779656	0.1007032	3.7533	0.0001745	***
drift	0.0269764	0.0026795	10.0678	< 2.2e-16	***

---  
Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Далее анализируем остатки на автокорреляцию с помощью теста Льюнга-Бокса



### Box-Ljung test

```
data: residuals(ma_gdp_1lag)
X-squared = 1.5377, df = 2, p-value = 0.4636
```

Остатки не автокоррелированы, из чего следует, что модель нам подходит (вероятность ошибки утверждать, что автокорреляция есть, достаточная).

### Построение модели AR

Ранее мы использовали PACF и выявили, что значим только лаг 1. Модель также построим через функцию ARIMA.


```
ar1_gdp= Arima(data$log_gdp, c(1,1,0), include.constant =TRUE, method =
c("CSS-ML"))
coeftest(ar1_gdp)
Acf(residuals(ar1_gdp))
Box.test(residuals(ar1_gdp), lag = 3, type = c("Ljung-Box"), fitdf = 1)
```

z test of coefficients:

	Estimate	Std. Error	z value	Pr(> z )
ar1	0.4149632	0.1140471	3.6385	0.0002742 ***
drift	0.0270503	0.0032705	8.2710	< 2.2e-16 ***

---  
Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Проверяем остатки на автокорреляцию



Box-Ljung test

data: residuals(ar1\_gdp)  
X-squared = 0.53277, df = 2, p-value = 0.7661

Исходя из теста вероятность ошибки высокая, соответственно, из этих данных делаем вывод, что модель нас устраивает, так как в остатках нет автокорреляции (это видно на графике и ещё более точно это показывает тест).

## Построение модели ARMA

Для построения этой модели используем EACF:


```
eacf(dif_gdp)
```

AR/MA	0	1	2	3	4	5	6	7	8	9	10	11	12	13
0	x	o	o	o	o	o	o	o	o	o	o	o	o	o
1	o	o	o	o	o	o	o	o	o	o	o	o	o	o
2	x	o	o	o	o	o	o	o	o	o	o	o	o	o
3	x	x	o	o	o	o	o	o	o	o	o	o	o	o
4	o	x	o	o	o	o	o	o	o	o	o	o	o	o
5	o	o	x	o	o	o	o	o	o	o	o	o	o	o
6	x	o	o	o	o	o	o	o	o	o	o	o	o	o
7	x	o	o	x	o	o	o	o	o	o	o	o	o	o

Для нас доступно много вариантов построения данной модели, однако мы минимизируем количество лагов, и поэтому нам подходит модель ARMA(1,1)

Строим модель с помощью функции ARIMA и проверяем остатки на автокорреляцию:

```
arma_gdp <- Arima(dif_gdp, c(1,1,1), include.constant =TRUE, method =
c("CSS-ML"))
coeftest(arma_gdp)
Acf(residuals(arma_gdp))
Box.test(residuals(arma_gdp), lag = 3, type = c("Ljung-Box"), fitdf =
2)
```



На графике автокорреляция не наблюдается

Box-Ljung test

```
data: residuals(arma_gdp)
X-squared = 1.9178, df = 1, p-value = 0.1661
```

$p > 0.1$ , поэтому утверждаем об отсутствии

автокорреляции в остатках.

Теперь выберем наиболее подходящую для прогноза модель из выведенных. На данный момент у нас их три: MA(1), AR(1) и ARMA(1,1)

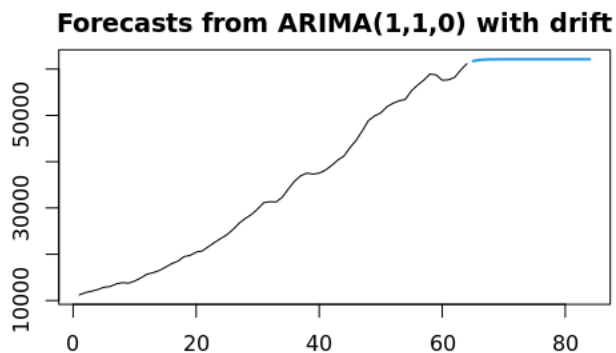
Для того, чтобы сравнить модели, используем метрики AIC И BIC и посмотрим, у кого этот параметр меньше.

```
ma_gdp_1lag$aic [1] -340.2212
ar1_gdp$aic     [1] -341.3407
arma_gdp$aic    [1] -333.7768
```

```
ma_gdp_1lag$bic [1] -333.7918
ar1_gdp$bic     [1] -334.9113
arma_gdp$bic    [1] -325.2683
```

Отсюда видим, что самое маленькое значение метрик у модели AR(1), также у неё самое большое p-value из данных. Тогда для прогноза ВВП на душу населения будем использовать эту модель. Делаем прогноз на 20 лет, так как это примерно треть от периода, который был дан ( $n = 64$ ).

### 3. Прогноз



**Построение прогноза для населения Норвегии**

## 1. Анализ стационарности


Данный показатель измеряется в годах и не подвержен инфляции. В данной ситуации не буду брать логарифм.

Посмотрим расф.

Value of test-statistic is: -1.5003 1.645

Critical values for test statistics:

	1pct	5pct	10pct
tau2	-3.51	-2.89	-2.58
phi1	6.70	4.71	3.86




Значимый лаг – 1

Сделаем тоже самое для первой разницы:

Value of test-statistic is: -2.1109 2.4482

Critical values for test statistics:

	1pct	5pct	10pct
tau2	-3.51	-2.89	-2.58
phi1	6.70	4.71	3.86




Значимые лаги – 1 и 2.

Сделаем для второй разницы:

Value of test-statistic is: -7.3698 27.1605

Critical values for test statistics:

	1pct	5pct	10pct
tau2	-3.51	-2.89	-2.58
phi1	6.70	4.71	3.86



Значимые лаги – 1,2 и 5


Соответственно, гипотеза о нестационарности числа населения и первой разности не отклоняется. Показатели - нестационарные. Для второй разности ситуация обратная – отвергаем нестационарность.

Будет использовать в дальнейшем ряд второй разности числа населения..

## 2. Анализ различий между спецификациями моделей AR, MA и ARMA


### Построение модели MA

Посмотрим на ACF. Значимые лаги исходя из графика – 1,2,3,5,6,9.



Построим модель MA(1) с помощью функции ARIMA

```
ma_pop1= Arima(data$Pop, c(0,2,1), include.constant =TRUE, method =
c("CSS-ML"))
coeftest(ma_pop1)
Acf(residuals(ma_pop1))
Box.test(residuals(ma_pop1), lag = 4 , type = c("Ljung-Box"), fitdf =
1)
```



z test of coefficients:

```
      Estimate Std. Error z value Pr(>|z|)
ma1  0.844189   0.059631  14.157 < 2.2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Проверим остатки.

Box-Ljung test

```
data: residuals(ma_pop1)
X-squared = 3.9527, df = 3, p-value = 0.2666
```

Исходя из результатов, видим, что значение достаточное, чтобы говорить об отсутствии автокорреляции в остатках.


Тогда строим МА(2):

```
ma_pop2= Arima(data$Pop, c(0,2,2), include.constant = TRUE, method =
c("CSS-ML"))
coeftest(ma_pop2)
Acf(residuals(ma_pop2))
Box.test(residuals(ma_pop2), lag = 4 , type = c("Ljung-Box"), fitdf =
2)
```

z test of coefficients:

```
      Estimate Std. Error z value Pr(>|z|)
ma1  0.770258   0.162130  4.7509 2.025e-06 ***
ma2 -0.076859   0.158166 -0.4859  0.627
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Посмотрим на остатки и проверим на автокорреляцию:



Box-Ljung test

```
data: residuals(ma_pop2)
X-squared = 3.8834, df = 2, p-value = 0.1435
```


Из этого следует, что автокорреляция отсутствует, а значит нам подходит данная модель.

Ещё построим МА(3):

z test of coefficients:

```
      Estimate Std. Error z value Pr(>|z|)
ma1  0.76432   0.12463   6.1327 8.64e-10 ***
ma2 -0.24555   0.14662  -1.6747 0.09399 .
ma3 -0.17348   0.11062  -1.5683 0.11681
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Проверим остатки на автокорреляцию:



Box-Ljung test

```
data: residuals(ma_pop3)
X-squared = 0.82176, df = 1, p-value = 0.3647
```

Мы видим, p-value маленькое ( $p > 0.1$ ), поэтому эта модель нам подходит.

Строим MA(5)

z test of coefficients:

	Estimate	Std. Error	z value	Pr(> z )
ma1	0.728736	0.203238	3.5856	0.0003363 ***
ma2	-0.276144	0.271535	-1.0170	0.3091647
ma3	-0.193261	0.125327	-1.5420	0.1230623
ma4	0.047629	0.345754	0.1378	0.8904351
ma5	0.075529	0.269981	0.2798	0.7796632

---  
Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Проверяем остатки

Box-Ljung test


```
data: residuals(ma_pop5)
X-squared = 3.6427, df = 0, p-value < 2.2e-16
```

Остатки данной модели сильно автокоррелированы.

Если строить модели по остальным значимым лагам, то получится, что p-value у них очень маленькое, что говорит о присутствии автокорреляции в остатках. Это происходит, потому что все последующие  $\text{fitdf} \geq \text{lag}$ .

## Построение модели AR

Смотрим на расф второй разницы числа населения:



Значимые лаги – 1, 2 и 5.

Строим модель AR(1) с помощью функции ARIMA:




```
ar_pop1= Arima(data$Pop, c(1,2,0), include.constant =TRUE, method =
c("CSS-ML"))
coeftest(ar_pop1)
Acf(residuals(ar_pop1))
Box.test(residuals(ar_pop1), lag = 4, type = c("Ljung-Box"), fitdf = 1)
```

z test of coefficients:

```
      Estimate Std. Error z value Pr(>|z|)
ar1  0.38007    0.11614   3.2726 0.001066 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Далее проверим остатки модели на автокорреляцию:



Box-Ljung test

```
data: residuals(ar_pop1)
X-squared = 15.437, df = 3, p-value = 0.001479
```

Из результатов следует наличие автокорреляции, поэтому можем сказать, что модель нам не подходит.

Далее строим AR(2):

z test of coefficients:

```
      Estimate Std. Error z value Pr(>|z|)
ar1  0.56552    0.11000   5.1412 2.730e-07 ***
ar2 -0.47828    0.10835  -4.4142 1.014e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Проверим остатки:

Box-Ljung test


```
data: residuals(ar_pop2)
X-squared = 4.4116, df = 2, p-value = 0.1102
```

Здесь нет автокорреляция в остатках, хоть значение и не большое.

Наконец строим AR(5) и проверяем остатки.

z test of coefficients:

```
      Estimate Std. Error z value Pr(>|z|)
ar1  0.67321    0.11780   5.7150 1.097e-08 ***
ar2 -0.66896    0.13945  -4.7970 1.610e-06 ***
ar3  0.39700    0.15455   2.5688 0.010205 *
ar4 -0.30650    0.13652  -2.2451 0.024761 *
ar5  0.33884    0.11347   2.9862 0.002824 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```



Box-Ljung test

```
data: residuals(ar_pop5)
X-squared = 1.9812, df = 0, p-value < 2.2e-16
```

Остатки модели сильно автокоррелированы.

## Построение ARMA

Строим EACF:

```
eacf(dif2_pop)
```

```
AR/MA
  0 1 2 3 4 5 6 7 8 9 10 11 12 13
0 x x x o x x o o x o o o o o
1 x x x o o x o o o o o o o o
2 o o x o o o o o o o o o o o
3 x o x o o o o o o o o o o o
4 x o x o o o o o o o o o o o
5 o x x o o o o o o o o o o o
6 o o x o o o o o o o o o o o
7 x o x o o o o o o o o o o o
```

Построим модель ARMA(2,1):


```
arma_pop <- Arima(data$Pop, c(2,2,1), include.constant =TRUE, method =
c("CSS-ML"))
coefest(arma_pop)
Acf(residuals(arma_pop))
Box.test(residuals(arma_pop), lag = 4, type = c("Ljung-Box"), fitdf =
2)
```

z test of coefficients:

	Estimate	Std. Error	z value	Pr(> z )
ar1	-0.0096604	0.1458810	-0.0662	0.9472
ar2	-0.1988426	0.1370955	-1.4504	0.1469
ma1	0.8022441	0.0948606	8.4571	<2e-16 ***

---  
Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Проверяем остатки:



### Box-Ljung test

```
data: residuals(arma_pop)
X-squared = 1.6418, df = 2, p-value = 0.44
```

Соответственно, в остатках нет автокорреляции, и мы можем использовать данную модель ( $p > 0.1$ ).

Исходя из рассмотренных моделях на данный момент у нас есть ARMA(2,1), MA(1), MA(2), MA(3) и AR(2).


Сравниваем модели по AIC и BIC:

arma_pop\$aic	[1] 251.3187
ma_pop1\$aic	[1] 249.4979
ma_pop2\$aic	[1] 251.254
ma_pop3\$aic	[1] 250.9178
ar_pop2\$aic	[1] 255.2798

Исходя из полученных результатов, лучше всего подойдёт модель MA(1), так как для неё AIC и BIC наименьшие. В своём прогнозе я буду использовать эту модель как лучшую.

arma_pop\$bic	[1] 259.8273
ma_pop1\$bic	[1] 253.7521
ma_pop2\$bic	[1] 257.6354
ma_pop3\$bic	[1] 259.4263
ar_pop2\$bic	[1] 261.6612


### 3. Прогноз



## Построение прогноза средней ЗП в Республике Карелия

### 1. Анализ стационарности

Будем использовать логарифм, так как зарплата не может быть отрицательной. Посмотрим PACF и сделаем DF тест. Зарботная плата уже скорректирована на инфляцию и сезонность.




Value of test-statistic is: -0.4463 20.335

Critical values for test statistics:

	1pct	5pct	10pct
tau2	-3.51	-2.89	-2.58
phi1	6.70	4.71	3.86

**Не отвергаем гипотезу о нестационарности.**

Теперь создаём первую разницу для этого показателя и также смотрим PACF и делаем тест на стационарность.



Value of test-statistic is: -9.0422 40.8916

Critical values for test statistics:

	1pct	5pct	10pct
tau2	-3.51	-2.89	-2.58
phi1	6.70	4.71	3.86

Т-статистика показывает маленькое значение, поэтому отвергаем гипотезу о нестационарности

показателя. Для построения моделей возьмём первую разницу заработной платы. На графике видим, что у нас один значимый лаг – 2.

## 2. Анализ различий между спецификациями моделей AR, MA и ARMA


### Построение AR модели

Значимый лаг – 2. Строим модель AR(2) с помощью функции ARIMA, после чего проверяем остатки на автокорреляцию.

z test of coefficients:

	Estimate	Std. Error	z value	Pr(> z )
ar1	-0.2828972	0.1109442	-2.5499	0.010775 *
ar2	-0.3242050	0.1099050	-2.9499	0.003179 **
drift	0.0180585	0.0015886	11.3675	< 2.2e-16 ***

---  
Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1




Box-Ljung test

data: residuals(ar\_w)  
X-squared = 3.1272, df = 2, p-value = 0.2094

P-value в тесте дало значение больше 0.1, поэтому мы говорим здесь об отсутствии автокорреляции в остатках.

## Построение МА модели

Смотрим на ACF для того, чтобы обозначить лаги, по которым строить модель. Значимый лаг – 2.




Строим модель МА(2) функцией

ARIMA и проверяем остатки на автокорреляцию:

```
ma_w= Arima(wage, c(0,1,2), include.constant =TRUE, method =  
c("CSS-ML"))  
coefest(ma_w)  
Acf(residuals(ma_w))  
Box.test(residuals(ma_w), lag = 4 , type = c("Ljung-Box"), fitdf = 1)
```

z test of coefficients:

```
      Estimate Std. Error z value Pr(>|z|)
ma1  -0.3234205  0.1173486 -2.7561  0.00585 **
ma2  -0.2563996  0.1124128 -2.2809  0.02256 *
drift  0.0182707  0.0010891 16.7760 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```



Box-Ljung test

```
data: residuals(ma_w)
X-squared = 0.38133, df = 3, p-value = 0.9441
```

Тест показал, что в остатках нет автокорреляции.

## Построение ARMA

```
eacf(d1)
```

AR/MA

	0	1	2	3	4	5	6	7	8	9	10	11	12	13
0	x													
1	x	x												
2	x	x	x											
3	x													
4	x		x	x										
5	x	x	x											
6	x			x										
7	x			x										

Модель MA(2) я уже построила, поэтому сейчас я построю модель ARMA(1,2)

z test of coefficients:

```
      Estimate Std. Error z value Pr(>|z|)
ar1  -0.2062911  0.3422934 -0.6027  0.54673
ma1  -0.1374007  0.3149351 -0.4363  0.66263
ma2  -0.3420614  0.1594711 -2.1450  0.03195 *
drift  0.0182356  0.0011112 16.4108 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Проверим остатки:

Box-Ljung test

```
data: residuals(arma_w)
X-squared = 0.10734, df = 2, p-value = 0.9477
```

Из этого следует, что остатки не автокоррелированы.

Итого мы получаем три модели без автокорреляции в остатках:

MA(2), AR(2), ARMA(1,2)

Сравниваем модели:

```
arma_w$aic [1] -344.9048
ma_w$aic   [1] -346.5574
ar_w$aic   [1] -344.6216
```

```
arma_w$bic [1] -333.4525
ma_w$bic   [1] -337.3956
ar_w$bic   [1] -335.4598
```

Мы получили, что наименьшее значение данных метрик имеет MA(1), также p-value больше, чем у модели AR(2). Для прогноза я буду использовать модель MA(1).

### 3. Прогноз

